智慧工廠預警 AI Agent

將感測回報轉成異常提醒、
檢查建議與可追蹤紀錄。

看懂異常

風險分級、三感測器趨勢

安排檢查

感測器核對與維修建議

留下紀錄

工單草稿、結果頁與交班

馬達驅動泵浦的單工況模擬

500 筆資料

每分鐘 1 筆

250 筆逐筆監測

從背景研究開始的 AI 協作

研究先行，分階段驗收；我確認後才接續實作。



下傳：交付結果　　上傳：我的回饋與修正要求

Skills 指導方法

grill-me / grilling　規劃

ponytail　簡化程式

設計與圖表 skills　呈現

code-review　審查與交付

ALL FREE AI TOOLS：兩種模型來源

Codex / Claude Code Agent 執行工作，推論來源可自由選擇。

選擇 A｜OmniRoute

串接免費 provider，依順序路由與備援。

auto-thinking｜規劃與推理

Groq gpt-oss-120b → NVIDIA NIM gemma-4-31b-it
→ Groq qwen3.8-27b

auto-coding｜程式實作

Mistral codestral-latest → OpenRouter
cohere/north-mini-code:free → Groq qwen3.8-27b



實際請求紀錄



候選路由配置

免費額度依各 provider 限制。

選擇 B｜Ollama

開源模型提供規劃、程式與文件推論。

Qwen3.8-27B Q8

qwen3.8:27b-q8_0

Qwen3-Coder-Next Q4

qwen3-coder-next:q4_K_M

Codex / Claude Code → Ollama

地端模型運行。

依據：docs/ai-tool-usage.md；左側為 OmniRoute 配置與請求證據，右側為 Ollama 模型選擇

Skills：把執行方法交給 Agent

SKILL.md 是可重用的任務指引，記錄情境、步驟、工具用法與驗收標準。



處理了 1 分鐘 41 秒 >

作業的評分重心是 **AI 工具使用 60%**、**任務完成 30%**、**技術報告 10%**，Live Demo 另有加分。因此，完整規劃除了四個技術部分，也必須包含 AI 使用證據、操作體驗，以及簡報與報告的交付驗收。 作業原文

已確認兩個重要細節：

- 嚴格門檻使用 `>`、`<`，等於邊界不算超標。作業中的 abnormal 範例也沒有任何感測器超過嚴格門檻，代表灰區異常是合理情境。
- `label` 是感測器或 AOI 的獨立判斷；這不要求統計上完全獨立，但需要說清楚它與偵測模型的關係，避免用同一套規則產生答案，再用它證明模型準確。

先進行需求確認，之後再進入你指定的全面盲點挑戰。依 grilling skill 的要求：「Ask the whole frontier in one round ... Then wait for the user's answers before the next round」，這輪只問目前可獨立決定的架構選擇；你的回答會決定下一輪細節。

❓ **Q1 — 設備情境**：是否同意以「單一、穩定工況的馬達驅動泵浦」作為示範背景，讓溫度、壓力、振動之間的關聯及維修建議有共同依據？

➡️ **建議：同意。** 使用作業指定數值；壓力與振動保留作業未註明單位的設定。根因輸出是附帶證據與驗證步驟的候選原因。

❓ **Q2 — Label 與評估的角色**：是否同意保留你提出的 label 生成方向，但讓感測器異常模型不把 `label` 當輸入；Agent 再整合 label 與感測器證據，且另留模擬事件註記供驗收？

➡️ **建議：同意。** 這樣可以展示「感測器先預警」「AOI 單獨異常」「兩者一致」三種情況。感測器正常但 label abnormal 時，先回報「判斷不一致、需檢查」，不能直接確診 AOI 故障。事件註記與五欄 CSV 分開保存。

實際需求問答：設備情境、感測訊號與 label 角色。

grilling 如何釐清需求

1　逐題追問

釐清假設、限制與未定細節。

2　確認一題，再往下問

我回答並核定關鍵決策。

3　把回答變成執行計畫

Agent 整理規格，我確認後實作。

先確認需求，減少反覆重寫。

SKILL.md 如何指導 Agent：兩個實例

把執行順序、工具用法與驗收條件寫清楚，Agent 才有一致的工作方法。

ponytail｜最小完整變更

ponytail/SKILL.md

1. 先讀任務與受影響的程式。
   確認呼叫端、設定與資料風險。
2. 先重用既有程式、標準庫與套件，
   再補上必要的新程式。
3. 選最小完整變更，
   保留驗證與必要的錯誤處理。

使用：依 ponytail，以最小完整修改完成任務。

ppt-master｜可編輯簡報

ppt-master / generate-pptx.md

1. 先整理內容、設計規格與頁面清單。
2. 以 SVG 製作版面，
   直接修改文字或提出標註。
3. 檢查版面、同步講稿與頁碼，
   再匯出可編輯 PPTX。

使用：用 ppt-master 製作可編輯簡報。

依據：ponytail/SKILL.md、ppt-master/SKILL.md 及 workflows/generate-pptx.md；重點改寫

原始資料：分布、關聯與 label

500 筆，每分鐘 1 筆

2026/11/07 12:00 起

欄位 / 精度	基線分布	正常作業條件	嚴格異常
temp / 1 位	N(47.5, 0.7²)	45–50°C	<43 或 >52°C
pressure / 2 位	N(1.025, 0.007²)	1.00–1.05	<0.97 或 >1.08
vibration / 2 位	Gamma(36, 0.03/36)	0.02–0.04	>0.07

AR(1) 係數 0.8；溫度–壓力 / 溫度–振動 / 壓力–振動：0.55 / 0.75 / 0.65。
溫度延遲 2 分鐘；相關設定描述量化前的潛在擾動。

label：嚴格超標 100% abnormal

先量化與產生 label，再加回傳故障；label 不作模型輸入。

62 筆 abnormal（12.4%）；12 格缺值、1 筆 999；原始 CSV 保留。

其餘依正常區外 0 / 1 / 2 / 3 欄

1% / 10% / 40% / 80%

生成順序

基線與時間關聯
常態 / Gamma / AR(1)

→

設備事件
突發 / 漂移 / 聯合灰區

→

量化與 label
1 / 2 / 2 位小數

→

回傳故障與缺值
保留已生成的設備 label

→

原始 CSV
500 筆，保留缺值

依據：generate_data.py、data/generation_metadata.json；常態與 Gamma 為事件注入、量化前基線

預設事件：讓系統遇到不同種類的問題

設備異常、回傳失效與穩態同值分開設計，觀察系統如何回應。

三感測器突發

16:29 | 第 270 筆

55°C / 1.12 / 0.10，三欄嚴格超標。

→ 綜合評估立即危急。

溫度漂移與恢復

16:54–17:48 | 第 295–349 筆

緩升至 55°C 後維持，再降回 47.5°C。

→ 第 301 筆模型警告，第 310 筆超標。

振動連續同值

18:04–18:11 | 第 365–372 筆

振動連續 8 筆完全相同。

→ 只記錄，不單憑同值告警。

壓力回傳 999

18:24 | 第 385 筆

注入不合理回報，不當成物理量測。

→ 資料品質警告。

灰區聯合異常

18:39–18:58 | 第 400–419 筆

三欄同時偏高，均未嚴格超標。

→ 持續 3 筆形成綜合警告。

溫度連續缺值

19:29–19:32 | 第 450–453 筆

保留缺值，有效前值最多暫補 2 分鐘。

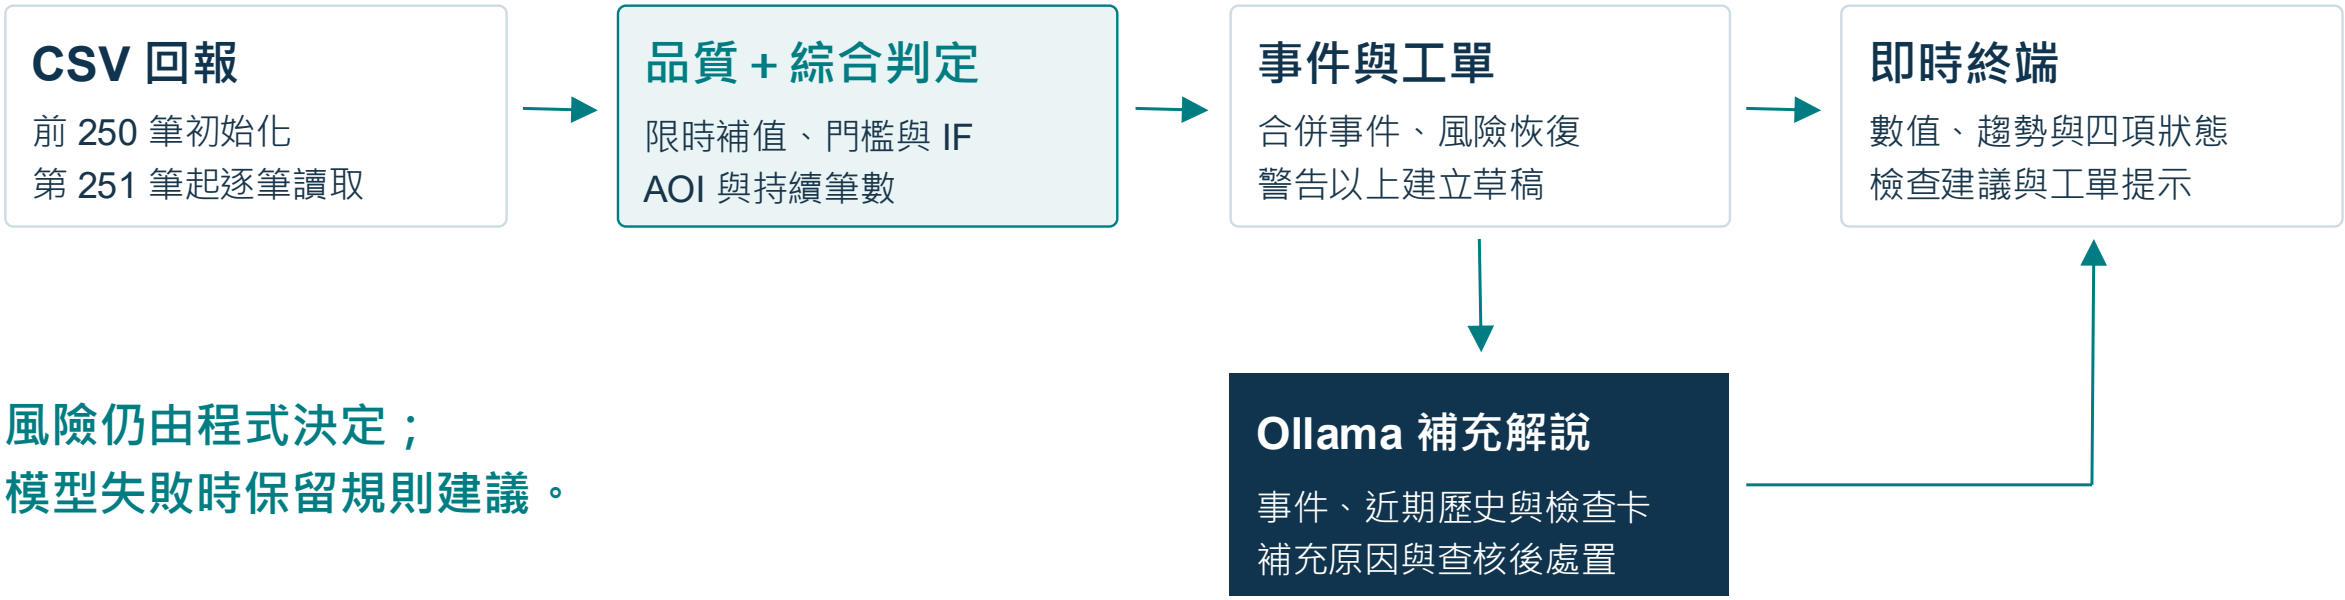
→ 超期後資料品質警告。

另有 8 格隨機缺值、正常量測但 AOI 異常；事件註記僅供驗收，不提供給偵測器。

系統架構：程式判定，模型補充解說

原始 CSV 唯讀；先完成判定與事件管理，再呈現建議、保存紀錄。

逐筆監測



風險仍由程式決定；
模型失敗時保留規則建議。

結束或中斷後保存：HTML 結果 / JSON 摘要 / SQLite 歷史

監測時逐筆追加 readings.jsonl；互動問答讀取已保存批次。

孤立森林：模型設計與預警表現

只看三個感測器，不使用 label；100 棵樹，固定模型逐筆評分。

前 200 筆 | 訓練
建立正常工況基準

後 50 筆 | 校準
分數轉為相對排名

後 250 筆 | 監測
依序更新分數與提醒

越容易被隔離，越偏離基線

隨機切分量測資料；異常點通常以較短的切分路徑被獨立出來。

0–100 是校準排名，非故障機率。
≥98 先關注，連續 3 筆模型警告。

98.6%
Precision

94.7%
Recall

96.6%
F1

0.983
原始分數 AP

9 分鐘提前警告

17:00 | 第 301 筆
模型警告

→

17:09 | 第 310 筆
首次嚴格超標

237 筆有效量測；152 筆安靜正常情境的模型新關注為 0。提前量為資料時間差。

四項狀態：用四個角度看同一筆回報

設備風險、資料可信度、工況變化與外部檢測分開判讀。

設備綜合評估

關注：灰區 / 模型 ≥98 / AOI 異常。
警告：嚴格超標，或持續異常 3 筆。
危急：雙欄嚴格，或同欄連 3 筆嚴格。

持續異常：模型高分、雙欄偏離或 AOI。

資料品質

關注：缺值有 2 分鐘內有效前值。
警告：999 / 非有限值 / 無可用前值。
暫補保留標記，原始 CSV 不改。

正常：三欄皆為有效原始回報。

運轉觀察

分數 <98：與平常相近。
分數 ≥98：與平常不同。
暫補中與資料不足，另行提示。

分數為相對基線的排名，並非故障機率。

AOI 設備監測

normal：當筆外部回報正常。
abnormal：當筆外部回報異常。
直接呈現 label，與綜合評估分開。

外部回報可與感測判斷不同。

設備事件保留最高風險；觸發消失且連 3 筆原始回報均有效才解除。模型單獨最高為警告。

依據：monitor.py、main.py；無完整量測且無其他證據或保留事件時，設備狀態為未知

何時建立工單？看事件的最高等級

任一事件最高等級達「警告」，系統就自動備妥待確認草稿。

關注

僅記錄事件，不開立草稿。

未達警告門檻。

警告

建立「優先檢查」草稿。

設備與資料品質事件皆適用。

危急

建立或升級為「緊急」草稿。

同一事件沿用原工單編號。

同一事件，只維護同一張草稿

例如 WO-E0005；
編號隸屬該次監測批次。

事件升級，更新優先程度

持續更新問題、證據與檢查建議，
保留事件最高風險。

告警恢復，草稿仍待確認

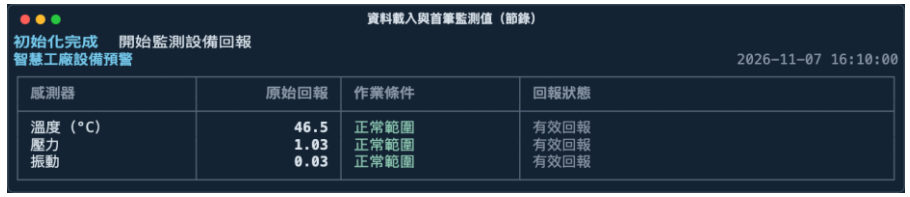
工單維持待確認草稿；系統不會自動派工，告警恢復也不代表維修完成。

依據：monitor.EventTracker.update、history_store.py；關注 <2、警告 =2、危急 =3

從資料載入，到即時監測

python main.py --no-ollama

1　載入資料



250 筆初始化
200 筆訓練 + 50 筆校準

第 251 筆起依序分析新回報。
同步更新提醒、趨勢與檢查建議。

2　查看監測與處置

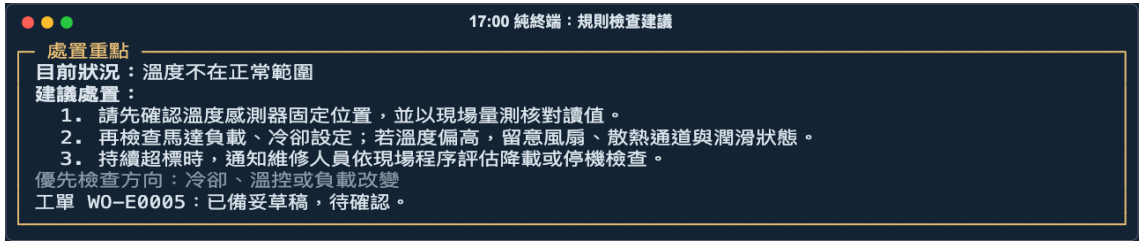


純終端與地端模型，差在哪裡？

同一筆 17:00 回報：風險與工單規則相同，解說方式不同。

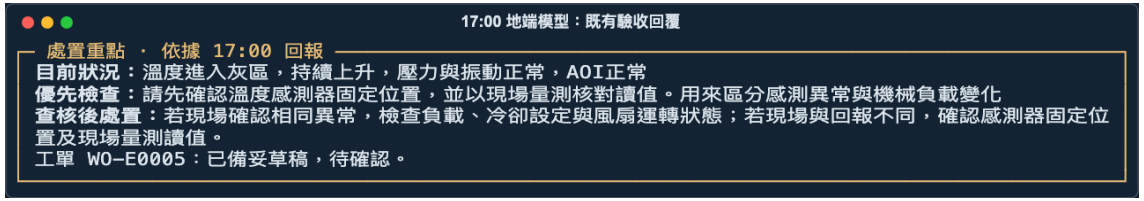
純終端

python main.py --no-ollama



地端模型

python main.py



固定檢查步驟

先核對感測器，再查負載、冷卻。
不需等待語言模型。

依當時證據補充解說

說明為什麼先查，以及查核後怎麼做。
「用來區分感測異常與機械負載變化」

LLM 補充情境與處置，不改變風險分級；失敗時保留規則建議。

閱讀結果、查詢交班與修改工單

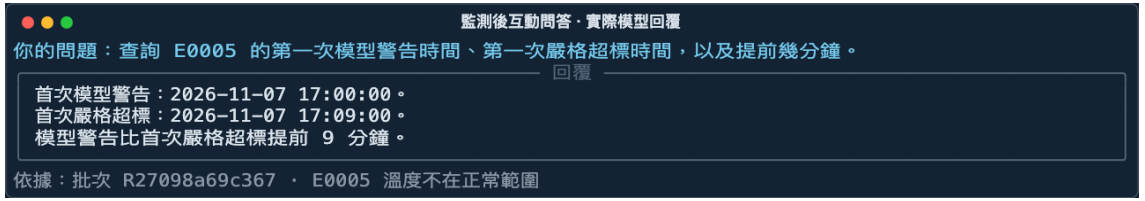
監測結束後閱讀中文結果；python main.py --chat 開啟三項問答。

離線閱讀結果



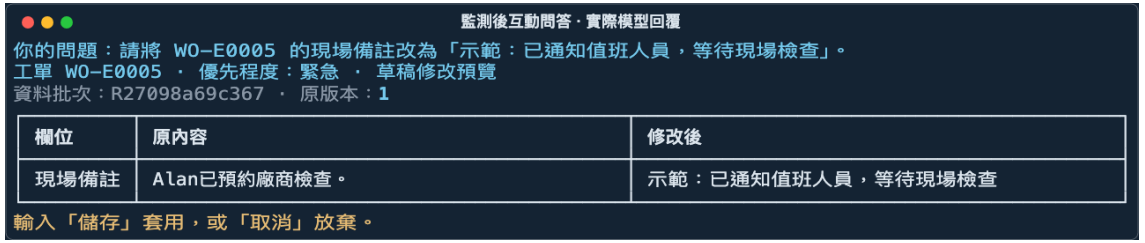
outputs/results.html

查歷史 / 整理交班



也可問：「整理本次交班摘要」。

工單修改先預覽



實際模型產生的備註預覽，尚未儲存。

從一句問題，到可核對的交班與工單

系統內的維修 Agent：Ollama ＋ qwen3:4b-instruct。

輸入問題
自然語言提出需求

→

Agent 選擇工具
只處理三項既定任務

→

讀取 SQLite 紀錄
依保存的事件與工單回答

查歷史

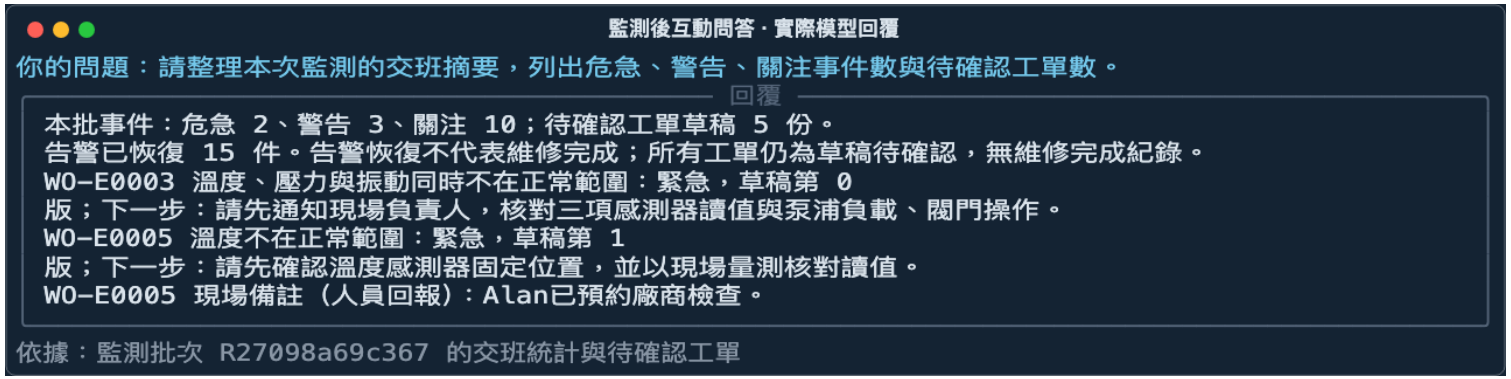
query_history

交班摘要

handoff_summary

改工單草稿

propose_work_order_edit



本次 Ollama 實際交班回覆，依據保存的批次與工單。

查詢 / 交班：模型選已查事實，程式帶入紀錄。
工單：預覽後確認，新增修訂版本。

GitHub | 程式、資料、README 與協作紀錄