智慧工廠設備異常預警 AI Agent

我以單一馬達驅動泵浦為情境，產生感測器 CSV，逐筆偵測設備異常並提供預警、分數紀錄與維修建議；結束後可讀離線結果、查歷史、整理交班及修改工單草稿。[1][2]

500 筆 / 每分鐘 1 筆 / seed 42　　2026/11/07 12:00-20:19（台北時間）

欄位 / 精度	基線分布	正常作業條件	嚴格異常
temp / 1 位	N(47.5, 0.7²)	45-50 ° C	<43 或 >52
pressure / 2 位	N(1.025, 0.007²)	1.00-1.05	<0.97 或 >1.08
vibration / 2 位	Gamma(36, 0.03/36)	0.02-0.04	>0.07

上表為量化與事件注入前的基線分布；Gamma 採 shape、scale。AR(1) 係數 0.8；溫壓／溫振／壓振的潛在擾動相關為 0.55／0.75／0.65；Gaussian copula 保留振動 Gamma 邊際，溫度落後共同波動 2 分鐘。這些潛在相關不等於量化後 CSV 的實測相關。[3]

label 生成：設備訊號在先，回傳故障在後

突發、溫度漂移、聯合灰區 → 1／2／2 位量化 → label → 同值、壓力 999、缺值。[3]

未嚴格超標：正常區外欄位數	0 欄	1 欄	2 欄	3 欄
P(label = abnormal)	1%	10%	40%	80%

量化後任一欄嚴格超標：100% abnormal，等於邊界不算超標；其餘依上表獨立抽樣，否則為 normal。全正常的 1% 模擬外部 AOI 誤報，非確認設備故障。seed 42 實得 62 筆 abnormal（12.4%），不強制改標湊比例。label 不因後加的回傳故障重算，也不作模型輸入。缺值共 12 格（連續 4 + 隨機 8 格），原始 CSV 保留。[3]

系統架構：程式判定風險，地端 Agent 提供解說

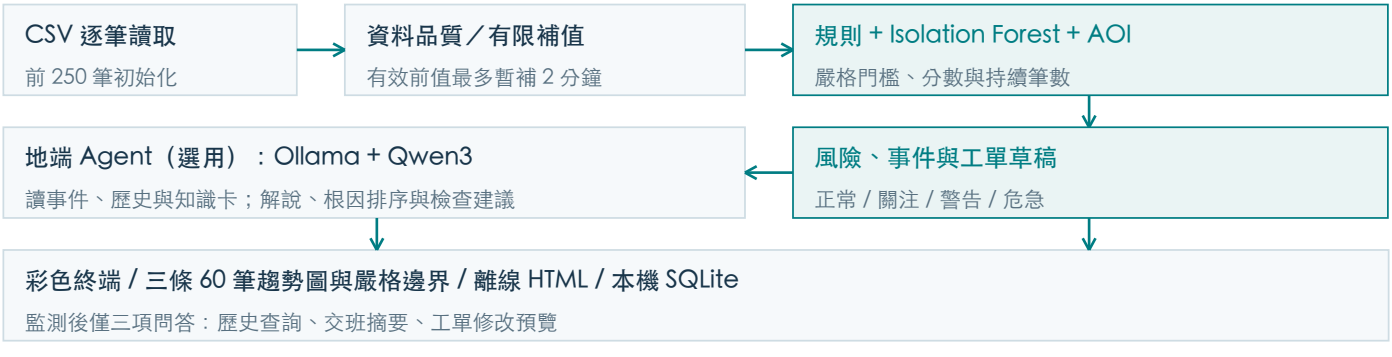


圖 1 | 同值僅記錄，不單獨告警；缺值不改原檔。LLM 失敗以規則備援；工單修訂須人工確認。

工作流程與資料載入示範

需求／計畫 → 資料驗收 → 純終端驗收 → 地端 Agent → 測試、PR 與文件審核。安裝 requirements.txt 後，以 python main.py --no-ollama 啟動。圖 2 為初始化與第 251 筆節錄；後 250 筆按資料時間監測。[2]

資料載入與首筆監測值（節錄）

初始化完成　開始監測設備回報
智慧工廠設備預警
2026-11-07 16:10:00

感測器	原始回報	作業條件	回報狀態
溫度（°C）	46.5	正常範圍	有效回報
壓力	1.03	正常範圍	有效回報
振動	0.03	正常範圍	有效回報

[1] 作業 v0.4 p1/4-5　[2] README　[3] 資料生成　[4] 模型評估　[5] AI 使用與截圖　[6] OmniRoute 官方　[7] Qwen Q8　[8] Coder Q4

四項狀態，分清設備與資料問題

設備綜合評估：符合多項時，採最高風險

危急	同筆至少 2 欄嚴格超標，或同一欄連續 3 筆嚴格超標。
警告	任一欄嚴格超標；或以下任一條件連續 3 筆：模型分數 ⩾98、至少 2 欄正常區外、AOI abnormal。
關注	任一欄正常區外、有效未暫補量測的模型分數 ⩾98，或 AOI abnormal。
正常	三欄有效，無上述觸發條件，且沒有未解除的設備事件。
未知	量測不完整，無其他異常證據，且沒有未解除的設備事件。

模型警告只計有效、未暫補量測；模型單獨最高為警告。正常區外包含嚴格超標，嚴格門檻仍優先。尚未解除的設備事件保留最高等級；觸發消失且三欄連續 3 筆原始有效回報後才解除。筆數依資料順序，與播放速度無關。

資料品質：看當筆原始回報

正常	三欄皆有限值且非 999。
關注	缺值，但最近有效前值距今 ⩽2 分鐘，先暫補。
警告	999／非有限值；或缺值無前值／距今 >2 分鐘。999 即使可暫補仍警告。

999 不當作設備嚴格超標；原值與暫補狀態保留。連續相同值不直接認定回傳故障。

運轉觀察：模型的當筆觀察

分數無法計算：資料不足，暫時無法判斷；使用暫補：部分資料暫補中，等待新回報確認；有效未暫補：⩾98 為「與平常不同」，否則「與平常相近」。

AOI 設備監測：外部標籤

直接顯示當筆 label：normal → 正常；abnormal → 異常。它與資料品質顯示當筆狀態，設備綜合評估則可能保留事件峰值。

Isolation Forest：固定模型，逐筆更新分數

前 200 筆訓練 | 50 筆校準 | 後 250 筆逐筆監測

三感測器、100 棵樹、random_state=42；監測不重訓。較短的平均隔離路徑對應較高原始分數 r = -score_samples(x)。score = 100 × (L + R) / (2 × N)：L／R 為校準原始分數 <r／⩽r 的筆數，N 為有效校準筆數（本次 50）；同分取中間排名，分數不是故障機率。[4]

98.6%	94.7%	96.6%	0.983
Precision	Recall	F1	原始分數 AP

237 筆完整量測，排除 13 筆缺值／999；以模擬設備事件窗口評估單筆模型提醒。152 筆事件外正常情境的新模型關注為 0。主種子已參與開發，結果不代表跨種子泛化或整合風險準確率。[4]

第 301 筆 17:00 模型警告，早於 17:09 嚴格超標

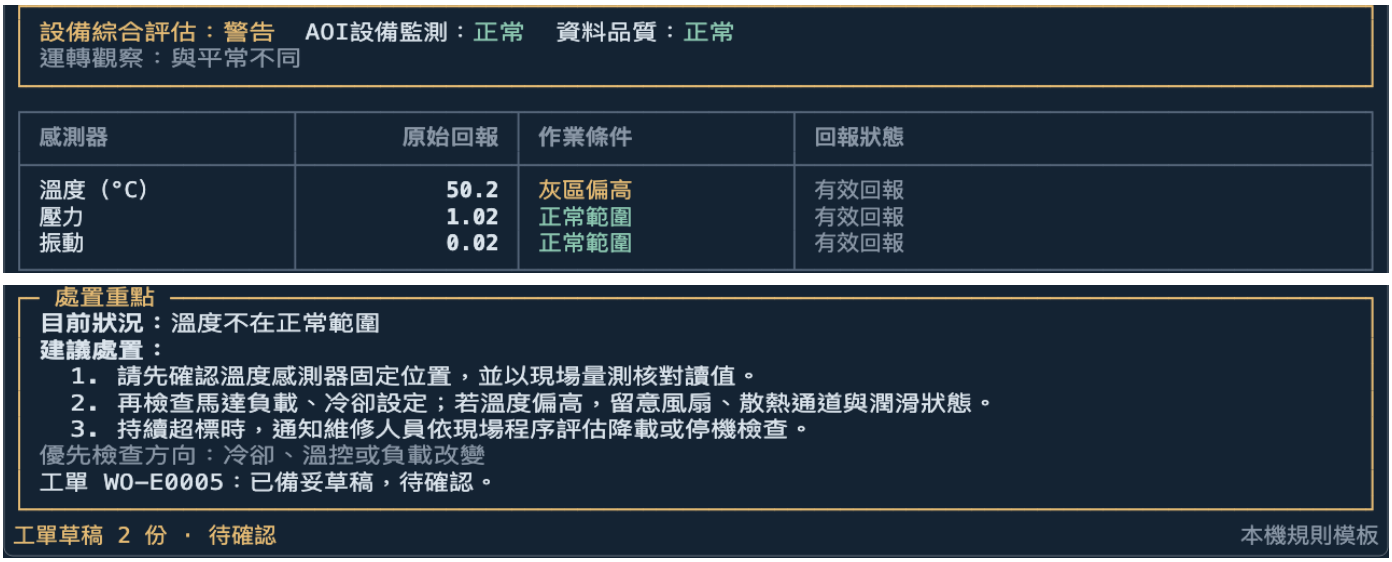


圖 3 | 純終端節錄；同筆 readings.jsonl 分數 100.0/100，畫面以「運轉觀察」呈現；提前 9 分鐘依資料時間。[2]

ALL FREE AI TOOLS

OmniRoute／Ollama，兩條開發 Agent 模型路徑

我討論計畫、審查程式與結果並授權。Codex／Claude Code Agent 負責操作檔案與工具；推論可選 OmniRoute 免費 provider 或 Ollama 開源模型，未用會員方案。背景初稿採 Gemini Deep Research 免費網頁版。[5]

Codex／Claude Code Agent → OmniRoute → 免費 provider（Groq／Mistral／OpenRouter）

Ollama：可選路徑　　Qwen3.8-27B Q8 ／ Qwen3-Coder-Next Q4

開發 Agent → Ollama → 上列任一模型，供規劃、程式與文件工作選用。[7][8]

OmniRoute 是可自架的 AI gateway，整合多個 provider 為相容 API 入口，按組合與優先順序路由；來源限流或失敗時，可嘗試後續可用目標，減少人工切換及反覆設定。免費額度由各 provider 提供且受其限制，並非 OmniRoute 贈送無限用量。[6]

我的 OmniRoute 配置與使用證據



圖 4 | 原始配置節錄：候選路由依優先順序嘗試；是否實際呼叫仍須看請求紀錄。[5]

規劃 / auto-thinking　　Groq gpt-oss-120b → NVIDIA NIM gemma-4-31b-it → Groq qwen3.8-27b

實作 / auto-coding　　Mistral codestral-latest → OpenRouter cohere/north-mini-code:free → Groq qwen3.8-27b

紀錄：OpenRouter stealth/crouton-alpha 回應 HTTP 200，亦保留失敗紀錄；來源以最終上游為準，組合可調整。[5]

Skills：讓 Agent 依可重用的方法執行任務

Skills 是可重用的任務指引，通常以 SKILL.md 記錄適用情境、步驟、工具用法與驗收標準。LLM 提供推論、Agent 操作工具、skills 指導方法；Agent 依任務套用，讓規劃、設計、審查與交付沿用一致流程，減少重述需求、無效修改與多餘 token。[5]

本專案以 grill-me／grilling 釐清規格、ponytail 簡化程式、code-review 核對規格與標準、frontend-design／圖表／PDF 指導視覺與文件，pr 整理提交證據。Agent 依此完成實作、測試、除錯、PR 與報告產製；我分階段驗收與授權。[5]

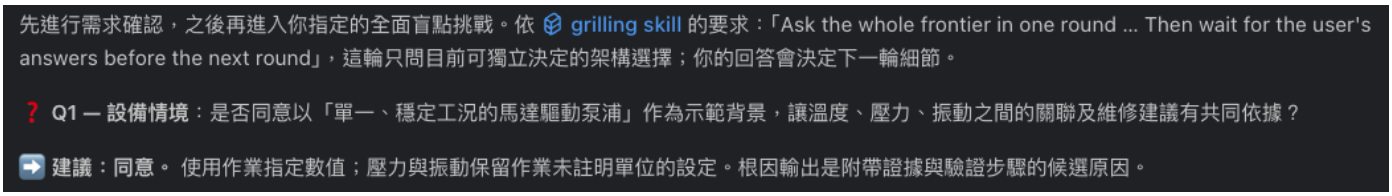


圖 5 | 規劃當時依 grilling skill 確認設備情境與限制（節錄）；完整截圖見 [5]。

工單草稿：預覽差異，確認後追加修訂

設備或資料品質事件達警告即建草稿，同事件沿用工單；警告為「優先檢查」、危急為「緊急」。只可修改問題摘要、工單說明、現場備註，風險／優先程度／證據受保護。輸入「儲存」才追加版本並保留原始快照；告警解除不代表維修完成，工單仍是草稿。[2]

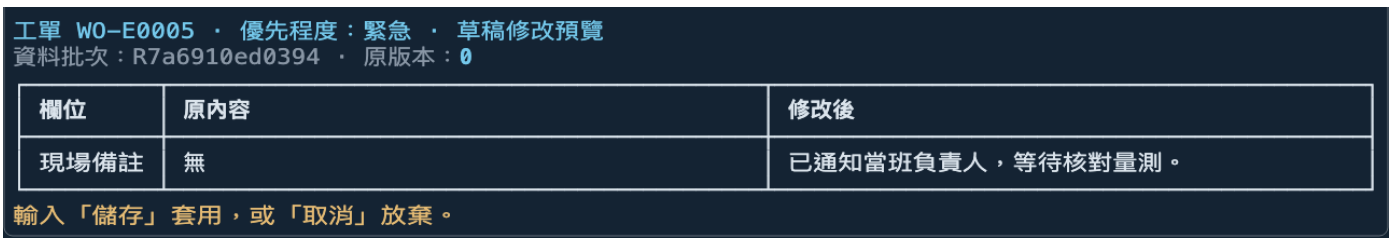


圖 6 | 監測後 WO-E0005 修改預覽示範（事件已升危急）：批次、版本及修改前後；尚未儲存。